

Clase 2

Notación del modelo paramétrico clásico

$$Y_i \stackrel{\text{iid}}{\sim} \text{Bernoulli}(\mu_i)$$

- Y_i y Y_j son independientes.
- Ambas tienen el mismo modelo
(f. de probabilidad o densidad)

Modelo "logístico" viene del modelo

$$Y \sim \text{Bernoulli}(\mu) \quad \text{Bernoulli}$$
$$P(Y=y) = \mu^y (1-\mu)^{1-y}, \quad y=1,0.$$

$$P(Y=1|X) =$$

Suponer que Y es dada

$$Y = \begin{cases} 1, & \text{si } A \text{ ocurre.} \\ 0, & \text{c.c.} \end{cases}$$

(Y, X) un modelo conjunto. Vé
existir el modelo condicional

$$Y|X=x \quad \text{o} \quad Y|x$$

Vamos a suponer que

$$F(x) = \frac{e^x}{1 + e^x}$$

$$u = P(Y=1|x)$$

Modelo

logístico

$$u = \frac{e^{\beta x}}{1 + e^{\beta x}} = P(Y=1|x)$$

No es único.

$$\mu = h(\beta \omega)$$

$$h: \mathbb{R} \rightarrow (0,1).$$

$$h: \text{logistica}, \text{ReLU}, \dots$$

Predictor lineal: βx

La función de link:

$$g(u) = \beta x$$

Con una muestra aleatoria

$Y_1 | x_1, \dots, Y_n | x_n$ iid.

$Y_i | x_i \sim \text{Bernoulli}(\mu_i)$

en que $\mu_i = \frac{e^{x_i^T \beta}}{1 + e^{x_i^T \beta}}$

$\mu_i = f_i(\beta), \beta = (1; \beta_1, \dots, \beta_p)$

Modelo Bayesiano Logistico

Ve existir una secuencia
 (Y_i, X_i, β) de vectores
aleatorios.

De forma analitica o de forma
computacional.

$$Y_1 | x_1, \beta, \dots, Y_m | x_m, \beta$$

El modelo supone que

$$Y_i | \mu_i, \beta \sim \text{Bernoulli}$$

$$\beta \sim N(\alpha, b)$$

$$x_i^T \beta$$

$$\mu_i = \frac{e^{x_i^T \beta}}{1 + e^{x_i^T \beta}}$$


Hiperparametros
 α y b .
• $P(\beta)$ un
modelo $N(\alpha, b)$

$$\beta = (\alpha, \beta_1, \dots, \beta_p)$$

Para estimarlos se toma

$$IE(\beta_i | y_i, x_i) = \beta_{0i}$$

Modelo para $\beta_i | y_i, x_i$
no tiene forma cerrada

El modelo logístico formal

$$\begin{aligned} \mathcal{X} &= \{0, 1\}^n, \\ (\mathcal{X}, \mathcal{F}, \{P_\beta : \beta \in \mathbb{R}^{p+1}\}) \end{aligned}$$

Modos conjugados

Modelo no paramétrico (funcional)

En general, cuando describo un modelo estadístico en base a una característica desconocida, esta media es llamada de "parametro" o de "target".

Funcionales de un modelo $(x, g, \{f_i\})$

$$\rightarrow E(x) = \int x dF(x)$$

$$\rightarrow \text{Var}(x) = \int \int 2(x_1 - x_2)^2 dF(x_1) dF(x_2)$$

$$\rightarrow F(x).$$

Modelo de ruido blanco

Gaussian con drift

$$\{Y(t) : t > 0\}$$

$$Y(t) = m(t)dt + \epsilon dW(t)$$

$$m(t) \in L^2(\mathbb{R}) : \int m^2(t) dt < \infty$$

$W(t)$: P.e. de Weiner.

$$E(Y(t)) = m(t)dt.$$

Paramétrico

θ

θdx

(H)

$\hat{\theta}$

Funcional

$m(t)$

$L^2(\mathbb{R})$

$\hat{m}(t) \parallel$

$$Y(t) = C + m(t) \Delta t + \epsilon dW(t)_{||}$$

C: conocido

ϵ : conocido

$W(t)$: es conocido

$m(t)$: es desconocida.

Presupuesto

$m(t) \in L^2(\mathbb{R}) : \int m(t)^2 dt < \infty$

$\exists \{\psi_k(t)\}$ para $L^2(\mathbb{R})_{i=1, \dots, r_{11}}$

que es una base lineal:

$$m(t) = \sum_k \alpha_k \psi_k(t)$$

$\{\psi_k\}_k$:

Spline

Fourier

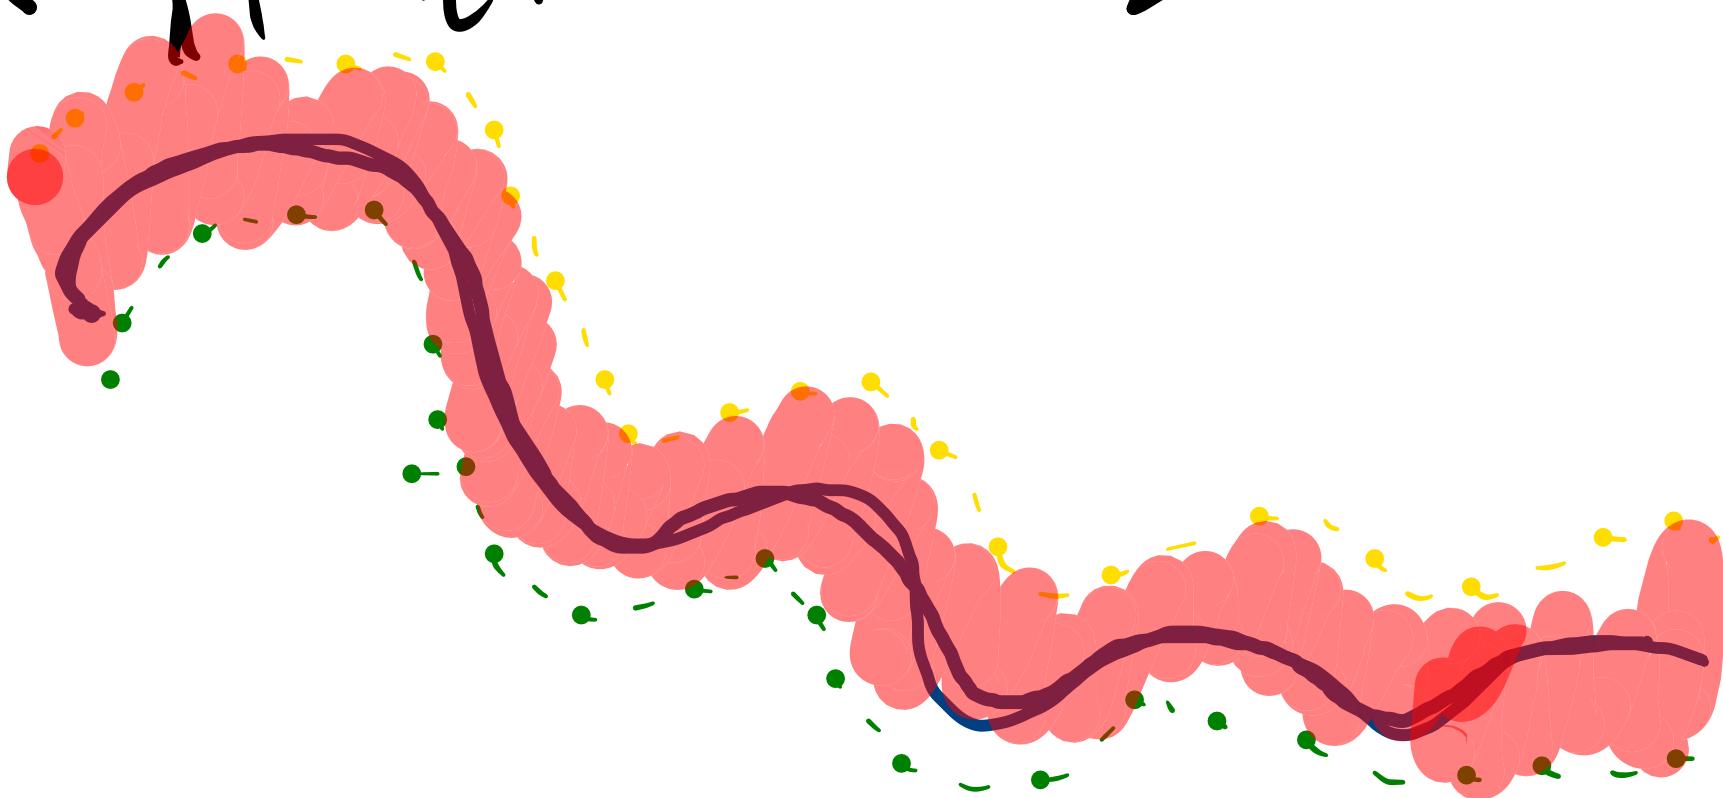
Polynomial

$\hat{m}(t) = \sum_{k=1}^{\infty} \hat{a}_k \psi_k(t).$

Wavelets

$$\hat{m}(t) = \sum_{k=1}^s \hat{a}_k \psi_k(t)$$

$$(\hat{a}_1, \hat{a}_2, \dots, \hat{a}_s)$$



$$(\alpha_1, \alpha_2, \dots, \alpha_m)$$

$$\alpha_i \sim N(0, \sigma_i)$$

$$\boldsymbol{x} = (x(t_1), x(t_2), \dots, x(t_{1020}))$$

$$\alpha_i | \boldsymbol{x} \sim \text{Posterior } II$$

$$I(x, y) = m(x, y) \cdot t + \epsilon dW(x, y)$$

Denoising image.

Familia de Modelos estadísticos

- > Familia exponencial
paramétrica: Poisson, Normal
- > Familia Generalizada de Valores extremos: Pareto, Gumbel
- > Familia elíptica.
- > Familia conjugada.

Def: Un modelo $(\mathcal{X}, \mathcal{G}, P_{\mathcal{H}})$

pertenece a la familia exponencial si $f_G = \frac{P_{\theta}}{h}$

se expresa como: $\langle \eta(\theta), T(x) \rangle - A(\theta)$

$$f(x) = h(x) e^{\langle \theta, \eta(\theta) \rangle}$$

$$\eta(\theta) = (\eta_1(\theta), \dots, \eta_d(\theta)) \text{ y } T(x) = (T_1(x), \dots, T_d(x))^T$$

$$\langle x, y \rangle = \sum_{i=1}^d x_i y_i .$$

Modèle de Poisson

$$P_\theta(x) = \frac{e^{-\theta} \theta^x}{x!}, \quad \theta \in \Theta = \mathbb{R}_+$$

$$= \frac{1}{x!} \exp\{-\theta + \log \theta^x\}$$

$$= \frac{1}{x!} \exp\{x \log \theta - \theta\}, \quad \theta \geq 1$$

$$h(x) = \frac{1}{x!}; \quad \eta(\theta) = \log \theta; \quad A(\theta) = \theta \quad ||$$

Modelos Normal $\mu \in \mathbb{R}_+$ y $\sigma^2 = 1$

$$f(x) = \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{(x-\mu)^2}{2}\right\}$$

" $\theta = \mu$ "

= .. .

$$= \frac{e^{-\frac{x^2}{2}}}{\sqrt{2\pi}} \exp\left\{x\mu - \frac{\mu^2}{2}\right\}, d=1$$

$\underbrace{\sqrt{2\pi}}$

$h(x)$

$\theta(\mu) = \mu$ $A(\mu)$

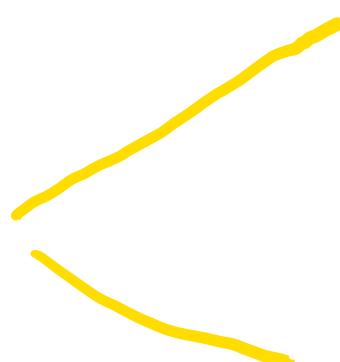
Estadística ($\mathcal{X}, \mathcal{Y}, \mathcal{P}$)

$$T: \mathcal{X} \rightarrow A$$

\downarrow

$$\mathbb{R}, \mathbb{R}^n$$

Información sobre θ (Suficiente)



sin Inf. sobre θ , que
mejora la precisión (Ancilares)

Informalmente, un estadístico T es suficiente para P_θ (para θ) si T contiene toda la información de x acerca de θ .

Un estadístico $A(x)$ es anciliar si su medida inducida P_A no depende de θ . Sir Ronald Fisher.

Def. Un estadístico $T: \mathcal{X} \rightarrow A$
es suficiente para P_θ

si

(i) $P_{\theta}(\mathbf{x} | T(\mathbf{x}) = t) = P(\mathbf{x} | T(\mathbf{x}) = t)$

(ii) $P_{\theta}(\mathbf{x} = \mathbf{x} | T(\mathbf{x}) = t)$ no depende
de θ

(iii) $f_{\theta}(\mathbf{x} | T(\mathbf{x}) = t)$

Def: T' es suficiente minimal
elkm es función de
toda estadística suficiente.

T · suf. $\vdash h : T' = h(T)$.

Minimal

Suf.

$$\{ \mathcal{G}(T') \subseteq \mathcal{G}(T) \}$$

Def.: $A: \mathcal{X} \rightarrow \mathcal{B}$ es ancilares para
cada P_θ en $(\mathcal{X}, \mathcal{G}, P_\theta)$ si

$$P_{\theta A} = P_A \text{ no depende de } \theta_{el}$$

Caso Bernoulli

$$P(X=x | T(x)=t) = \frac{1}{\binom{m}{t}}, \text{ no depende de } \theta$$

(x_1, \dots, x_m)

t : nù de 1's.

$$T(x) = \sum_{i=1}^m x_i$$

Modelo Uniforme