

NL $\beta$

$\beta_i | y_i, x_i \sim \text{Model}(n) = i?$


$\beta_i \sim \text{Normal}(0, \sigma_i)$

$E(\beta_i | y_i, x_i^T) = \text{"mean"}$

HDI: high density interval  
( $a, b$ )

$P(a < \beta_i | y_i, x_i^T < b) = 0,97 (97\%)$


$$\beta_i | y_i, \chi_i^+$$



$$\beta_i \sim N(0, 2)$$


$$\beta_i | y_i, x_i \sim \text{Model 0 (?)}$$

It. 1:  $\rightarrow$  Model 0.1:  $\beta_i^1 | y_i, x_i$




It. 2: Model 0.2:  $\beta_i^2 | y_i, x_i$

Converges



It. 5000: Model 5000:  $\beta_i | y_i, x_i$

5000



$\rightarrow t \geq 4000$ , Esiste convergenza

$$\rightarrow \beta_t \xrightarrow[t=4000]{\text{5000}} \bar{\beta} = \frac{1}{1000} \sum_{i=1}^{1000} \beta_i^t$$

$$P(\beta^t | \beta^{t-1})$$


) Gibbs sampling

> Variational sampling. ✓

## Clase 3

- Familia exponencial
- Reducción de  $X$  por estadísticas.
- Información de Fisher.

$\mathcal{P} = \{ P : P \text{ cumple alguna prop.}\}$  Modelos



# Parte I

[ Familia exponencial ]

## Familia exponencial

$$\langle \eta(\theta), T(x) \rangle - A(\theta)$$

$$P(x) = h(x) e^{\int_{\theta}^x}$$

$$\langle \eta(\theta), T(x) \rangle = \sum_{i=1}^d \eta_i(\theta) T_i(x) \rightarrow \eta(\theta) T(x).$$

Forma especial

$$P(x) = a(\theta) h(x) e^{\langle \eta(\theta), T(x) \rangle}; \quad a(\theta) = e^{-A(\theta)}$$

Ejemplo: modelo logístico

Continuo:  $P_{\theta}(X \in A)$ ;  $\mu$ : Lebesgue

$$\mu(A) = 0 \Rightarrow P_{\theta}(X \in A) = 0$$

Discreto:  $P'_{\theta}(X \in B)$ ;  $\mu$ : conteo

$$P_{\theta}(X \in A) = \sum_{x \in A} a(\theta) h(x) e^{\langle \theta, T(x) \rangle} d\mu(x) < \infty$$

# Propiedades del espacio paramétrico. 2.1

Si  $\eta(\theta) = \theta$ , entonces  $P(x) = \underline{\alpha(\theta) h(x) e}$ .

(H) es el espacio paramétrico

$$H = \left\{ \theta : \int n(x) e^{\langle \theta, T(x) \rangle} d\mu(x) < \infty \right\}$$

$$\eta(\theta) = \theta.$$

Resultado: (H) es convexo.

## Implicaciones

- > El ENV es único
- > Los algoritmos – serán eficientes.
- > Estabilidad en regularización y penalización
- > Asegura que siempre habrá convergencia.

## Ejemplo: modelos logísticos

$$\theta \rightarrow p$$

a. o o

$$P_{\beta}(y) = \exp[y \cdot x^T \beta - \log(1 + e^{x^T \beta})]$$

$$T(y) = y; \quad \eta(\beta) = x^T \beta; \quad A(\beta) = \log(1 + e^{x^T \beta})$$

$$h(y) = 1.$$

> En general, todo MLG.

• Propiedad: cambio en el orden de integración y derivada

$$P_0(x \in A) = a(\theta) \underbrace{\int_{-\infty}^{\theta, T(x)} h(x) e^{\int_x^{\theta} d\mu(u)} du}_{*} < 00$$

$$\ell(x) = g(x) h(x) \quad X, x, Y, y_i$$

$$IE(|\ell(x)|) = a(\theta) \left| \int_{-\infty}^{\theta, T(x)} [h(x)]' e^{\int_x^{\theta} d\mu(u)} du \right|$$

Caso 1:  $\ell(x) = 1$ . o  $\ell(x) = g(x) h(x)$

Caso 2:

# Aplicación al modelo Logístico

Para alguna  $\ell(x)$  (1)

$$\mathcal{H}_\ell \subseteq \mathcal{H}_{\parallel}$$

$$\langle \theta, \ell(x) \rangle$$

$$m(\theta) = \int \ell(x) e^{\langle \theta, \ell(x) \rangle} d\mu(x)$$

- Es continua ( $\theta \in \mathcal{H}_\ell$ )
- $m^{(r)}(\theta)$  existe  $\forall r \in \mathbb{N}$ .

$$\theta = (\theta_1, \dots, \theta_p)$$

$$\frac{\partial m(\theta)}{\partial \theta_i} = \int_{\mathbb{R}} x_i p(x) e^{\langle \theta, x \rangle} d\mu(x),$$

Condiciones de regularidad sigloc

↓ sobre

$$\mathcal{C}_H = \{P_\theta : \theta \in H\},$$

# Aplicación de la familia exponencial a Data Science

-

# Ronald Fisher //

$(\mathcal{X}, \mathcal{G}, \mathcal{P})$

Parte 2

Suficiencia

Anciarianidad

Completitud

$T: \mathcal{X} \rightarrow \mathcal{Y}$

$\dim(T(x)) \leq \dim(x) //$

- $T$  que resume sin perder información //
- $A$  que no tengo información sobre  $\theta$ .

# Propiedad de una estadística suficiente

- $P_{\theta}(X \in A | T(x) = t) = P'_t(X \in A, t)$
- $P_{\theta}(X = x | T(x) = t) = P_t(X = x)$
- $T(x)$  tiene toda info. de  $x$  sobre  $\theta$ .
- $P_t(x)$  es invariante con respecto a  $\theta$

## Inferencia

$P_\theta$  que  $X = x_0$  desconocida

$$P_\theta(x \in A | T(x) = t) = P'_t(x \in A)$$

$$T(x) = t$$

conocida

Simular muestras de  $X (x_1, \dots, x_k)$   
desde  $P'_t(x \in A) = (p_1, p_2, \dots, p_k)$

## Bernoulli

$\alpha \in \{0, 1\}^n$ ,  $x = (0, 1, 0, 0, \dots, 1)$

$$P(X = \alpha | T(\alpha) = t) = \frac{1}{m} \quad (\neq x)$$

$\alpha_1 | T=t, \dots, \alpha_n | T=t$

Model  
Uniform

$$T' = \frac{1}{n} \sum x_i$$

$$T'' = g(T)$$


$$\sigma(T) \neq \sigma(T')$$
$$\neq \sigma(T'')$$

# Estadística suficiente

## mínimal

- >  $T^*$  es suf. minimal si es función de toda estadística suficiente  $T$ .  
y suficiente  $\exists h: T^* = h(T)$
- >  $\sigma(T^*) \subseteq \sigma(T) \subseteq \sigma(X)$

# Sigma algebras suficientes



# Estadística completa e anciliar

A:

$X \rightarrow A$  es anciliar para  $\theta$ ,  
si no tiene información sobre  
 $\theta$ .

$$P_{\theta}(A \in Z) = P(A \in Z) \quad \forall \theta \in \Theta$$

C:

$X \rightarrow C$  es llamado de Completo  
Si  $C$  es suficiente y no tiene  
información anciliar.  $|(\delta, L, P_A)$   
 $Z \in \mathcal{Z}$ .

## Teorema de Basu

T es completa y A es  
ancilar  $\Rightarrow$

$$\dot{T} \not\propto A_{||}$$

$\rightarrow$  I.C.

# Teorema de la factorización



## Ejemplo de aplicación

La estadística

$$T(Y) = \sum_{i=1}^n Y_i X_i^T$$

suficiente para  $P_\beta$ .



Parte 3

[Información de Fisher]

Curvatura  $\frac{\partial \log L(\theta)}{\partial \theta} \Big|_{\theta=\hat{\theta}}$

$$\mathcal{H} = \{P_\theta : \theta \in \Theta\} \quad p_\theta(x) = \frac{dP_\theta}{d\mu(x)}$$

$$\theta = (\theta_1, \dots, \theta_p)$$

#### Definición 2.4 Función Score e Información de Fisher

Suponga que se cumplen las condiciones de regularidad de la Información de Fisher. El vector score se define como  $\frac{\partial \log p_\theta(X)}{\partial \theta_i}$  para  $i = 1, \dots, d$ . La Información de Fisher  $I_X(\theta)$  es la matriz de covarianza del vector score; es decir,

$$I_X(\theta)_{ij} = C_\theta \left( \frac{\partial \log p_\theta(X)}{\partial \theta_i}, \frac{\partial \log p_\theta(X)}{\partial \theta_j} \right). \quad (6)$$

Se tiene que el valor esperado del score es cero. En este caso, si podemos diferenciar dos veces dentro del signo integral (como en familias exponenciales; cf. Teorema 1), entonces hay una fórmula alternativa para la Información de Fisher:

$$I_X(\theta)_{ij} = -\mathbb{E}_\theta \left\{ \frac{\partial^2}{\partial \theta_i \partial \theta_j} \log p_\theta(X) \right\}.$$

$i = j$


$$\underline{I}_x(\theta_i) = \underline{I}_x(\theta)_{ii}$$

$$\underline{I}_x(\theta) = (\underline{I}_x(\theta_1), \dots, \underline{I}_x(\theta_p))$$

~~$\neq$~~

$I(\theta)$  es una medida la  
curvatura de  $\ln L(\theta)$

$$\ln L_{x_1}(\theta) = \ln L(\theta)$$



## Teorema

$$I(\theta) = \frac{I(\theta)}{T}$$

si  $T$  es suficiente

# Interpretación geométrica

Resultados

# Aplicaciones a Data Science