

Teoría Estadística. Unidad II

Dr. Jaime Lincovil

Universidad Nacional de Ingeniería

2025

- 1 Elementos de pruebas de hipótesis. Lema fundamental de Neyman-Pearson. Test uniformemente más poderoso**
- 2 Test de la razón de verosimilitud Monótono. Test Uniformemente Más Poderosos (UMP) Bilaterales**
- 3 Test insesgados, Razón de Verosimilitud Generalizada (RVG), función de evidencia y propiedades asintótica.**
- 4 Tests del tipo Chi-cuadrado.**
- 5 Test no paramétricos.**

Elementos de pruebas de hipótesis. Lema fundamental de Neyman-Pearson. Test uniformemente más poderoso

Contraste/prueba/test de hipótesis

Definición 31. Prueba/contraste de hipótesis

Una **hipótesis estadística** es una afirmación lógica acerca de la población P_θ . Un **contraste de hipótesis estadístico** consiste en dos hipótesis estadísticas contrastando diferentes (parcial o totalmente) características de P_θ . Sea una $\mathcal{P}$ clase de medidas de probabilidad indexadas por θ , luego, la **hipótesis nula y alternativa** son hipótesis estadísticas definidas en términos de clases disjuntas dada por:

$$H_0 : P_0 \in \mathcal{P}_0 \quad \text{versus} \quad H_1 : P_0 \in \mathcal{P}_1,$$

en que $\mathcal{P}_0 \cap \mathcal{P}_1 = \emptyset$ en la mayoría de los casos.

Nota: de entre Contraste/prueba/test, emplearemos **test**.

Procedimiento de decisión

Definición 31. Procedimiento de decisión de un test

Sea $\mathbb{A} = \{0, 1\}$, en donde 1 significa rechazar H_0 , entonces, $T : \Lambda \rightarrow \mathbb{A}$ es llamada de **función (decisión) test** con

$$T(X) = \begin{cases} 1, & \text{Rechazamos } H_0 \\ 0, & \text{No rechazamos } H_0. \end{cases}$$

La **región de rechazo** A_1 y **no rechazo** A_0 de H_0 es una partición de Λ :

$$A_1 = \{x \in \Lambda : T(x) = 1\} \cup A_0 = \{x \in \Lambda : T(x) = 0\} = \Lambda.$$

Para decidir entre H_1 y H_0 consideramos una función de perdida $L(\theta, T)$ y riesgo medio $R_T(\theta) = E_j[L(\theta, T)]$, según $P_\theta \in \mathcal{P}_0$ o $P_\theta \in \mathcal{P}_1$.

Nota: Un procedimiento de decisión de una prueba consiste en construir las regiones A_1 y A_2 basado en un fijar un error mínimo y/o maximizar el poder detección de un test .

Errores y sus probabilidades

Definición 32. Error del tipo I y Tipo II

Table: Posibles errores al decidir sobre H_0 .

	H_0 es verdadera	H_0 es falsa
No rechazar H_0	Correcta	Error tipo II
Rechazar H_0	Error tipo I	Correcta

Error tipo I: $T(X) = 1$, es decir, rechazamos H_0 , a pesar de que esta es verdadera. **Error tipo II:** $T(X) = 0$, es decir, NO rechazamos H_0 , a pesar de que esta es falsa.

Definición 33. Probabilidades del error del tipo I y Tipo II

La probabilidad del error tipo I: $R_T(\theta) = P_\theta(T(X) = 1) = \alpha$, dado que $P_\theta \in \mathcal{P}_0$. **La probabilidad del error tipo II:** $R_T(\theta) = P_\theta(T(X) = 0) = \beta$, dado que $P_\theta \in \mathcal{P}_1$.

Función poder de un test

Definición 34. Función poder de un test

$$\Gamma_T(\theta) = P_\theta(T(X) = 1) = 1 - \beta, \text{ dado que } P_\theta \in \mathcal{P}_1.$$

Es la probabilidad de rechazar H_0 para un cierto $P_\theta \in \mathcal{P}_1$. En palabras, simples, la probabilidad de rechazar H_0 cuando esta es falsa.

Definición 35. Test de nivel α

Una función test T es llamada de **función test de nivel α** si y solamente si

$$\sup_{P_\theta \in \mathcal{P}_0} \{P_\theta(T(X) = 1)\} \leq \alpha, \quad \alpha \in (0, 1).$$

Es decir, la probabilidad del error tipo I es como máximo α .

Nota:

Test Uniformemente más Poderoso (TUP)

Definición 36. Test Uniformemente más Poderoso (TUP)


Una función test T' de tamaño α es llamado de **Test Uniformemente más Poderoso** (TUP) para decidir sobre las hipótesis H_0 y H_1 si y solamente si

$$\Gamma_T(\theta) \leq \Gamma_{T'}(\theta) \quad \forall P_\theta \in \mathcal{P}_1,$$

para todo otra función test T de nivel α .

Nota: Un test T' de nivel α es TUP si su poder es mayor o igual al poder de cualquier otro test T para cada $P_\theta \in \mathcal{P}_1$.

Visualización del Test Uniformemente Más Poderoso



Medidas sobre hipótesis H_0 y H_1

- Sea $P_0 \in \mathcal{P}$ y $P_1 \in \mathcal{P}_1$ dos medidas de probabilidad pertenecientes a las subfamilias que especifican H_0 y H_1 , respectivamente.
- Denotamos por $f_0(x)$ y $f_1(x)$ las funciones de densidad de P_0 y P_1 , respectivamente. Alternativamente, podríamos denotar las densidades por $f_{\theta_0}(x)$ y $f_{\theta_1}(x)$, respectivamente.
- La probabilidad de un evento $A(X)$ sobre la hipótesis H_0 es denotado por

$$P_0(A(X)).$$

Análogamente, para H_1 y $P_1(A(X))$.

- El valor esperado de una función $\psi(X)$ sobre la hipótesis H_0 es denotada por

$$E_0(\psi(X)) = \int \psi(x)f_0(x)dx.$$

Análogamente, $E_1(\psi(X)) = \int \psi(x)f_1(x)dx$ para H_1 .

Lema de Neyman-Pearson (LNP)

Teorema 16. Lema de Neyman-Pearson

Consideremos las subfamilias $\mathcal{P}_0 = \{P_{\theta_0}\}$, $\mathcal{P}_1 = \{P_{\theta_1}\}$ y sea f_{θ_j} la densidad de P_{θ_j} para $j = 0, 1$. (i) Existencia de un TUP. Para todo α , existe un TUP de tamaño α dado por

$$T(X) = \begin{cases} 1, & Y > c(U) \\ \gamma, & Y = c(U) \\ 0, & Y < c(U). \end{cases}$$

en que $\gamma \in [0, 1]$ y c son constantes elegidas tales que $E_0[T'(X)] = \alpha$ en el caso de que $P_\theta = P_{\theta_0}$. (ii) Unicidad. Si T' es un TUP de tamaño α , entonces:

$$T(X) = \begin{cases} 1, & f_{\theta_1}(X) > cf_{\theta_0}(X) \\ 0, & f_{\theta_1}(X) < cf_{\theta_0}(X). \end{cases}$$

Ejemplo media Normal contra Exponencial doble

- Sea una muestra de una observación $X = x$, en que $\mathcal{P}_0 = \{P_0\}$ y $\mathcal{P}_1 = \{P_1\}$, en que $P_0 \sim \text{Normal}(0, 1)$ y $P_1 \sim \text{D-Exponencial}(0, 2)$ con densidades f_0 y f_1 , respectivamente.
Dado que $P[f_1(X) = cf_0(X)] = 0$, un test T del tipo TUP tiene la forma:

$$T(X) = \begin{cases} 1, & f_{\theta_1}(X) > cf_{\theta_0}(X) \\ 0, & f_{\theta_1}(X) < cf_{\theta_0}(X). \end{cases}$$

- Es posible de demostrar que $f_1(X)/f_0(X) > c$ ssi $\frac{\pi}{8}e^{\frac{x^2}{2} - \frac{|x|}{2}} > c$.
- Lo cual es equivalente a $|x| < t$ o $|x| < 1 - t$ para $t > 1/2$.
- El valor de t que le da a T un tamaño α es dado por $t = \Phi^{-1}(1 - \alpha/2)$ y el TUP tiene la forma

$$T(X) = \begin{cases} 1, & |X| > t \\ 0, & \text{caso contrario.} \end{cases}$$

Ejemplo modelo Bernoulli

- Sea $X_1, \dots, X_n$ una muestra tal que $X_i \sim \text{Bernoulli}(p)$. Consideremos las hipótesis $H_0 : p = p_0$ contra $H_1 : p = p_1$ en que $0 < p_0 < p_1 < 1$.
- Por el LNP un TUOP de tamaño α tiene la forma:

$$T(X) = \begin{cases} 1, & \lambda(Y) > c \\ \gamma, & \lambda(Y) = c \\ 0, & \lambda(Y) < c. \end{cases}$$

en que $\lambda(Y) = \left(\frac{p_0}{p_1}\right)^Y \left(\frac{1-p_0}{1-p_1}\right)^{n-Y}$.

- Para encontrar el test T es necesario encontrar m tal que

$$\alpha = E_0(T(X)) = P_0(T(X) = 1) + \gamma P(Y = m).$$

- El valor de γ es seleccionado de manera de completar lo que falte para que el valor esperado sea exactamente igual a α .

Extensión del LNP

Proposición 4.

Supongamos que existe un test T' de tamaño α tal que para toda $P_\theta \in \mathcal{P}_1$ es un TUP para testar $H_0 : P_\theta = P_0$ contra la alternativa $P_\theta = P_1$ para toda $P_1 \in \mathcal{P}_1$. Entonces, T' es también TUP para testar

$$H_0 : P_\theta = P_0 \quad \text{contra} \quad H_1 : P_\theta \in \mathcal{P}_1.$$

Ejemplo de la extensión del LNP

- Sea $X_1, \dots, X_n$ una muestra de una población Normal $(\mu, 1)$. Consideremos las hipótesis $H_0 : \mu = 0$ contra $H_1 : \mu = 1$.
- Es posible demostrar que

$$\frac{f_1(X)}{f_0(X)} = e^{\sum_{i=1}^n x_i - \frac{n}{2}} \geq c,$$

- O, equivalentemente, $T(X) = 1$ cuando $\sum_{i=1}^n x_i \geq c'$, para alguna constante c' .
- Para $\alpha = 0.05$, necesitamos una constante c' tal que $P_0(\sum_{i=1}^n X_i \geq c') = \alpha$ de tal manera que el test sea de nivel $\alpha = 0,05$. Dado que $\sum_{i=1}^n X_i \sim \text{Normal}(0, n)$, el la constante es dada por $c' = 1,64\sqrt{n}$.
- El test que rechaza H_0 es TUP. Dado que el mismo test continua siendo TUP para todo $\mu > 0$, entonces el es un TUP para testar $H_0 : \mu = 0$ contra $H_0 : \mu > 0$. Este debido a que la región crítica $\sum_{i=1}^n x_i \geq c'$ no depende de un particular valor de $\mu > 0$.

Ejemplo de test Bayesiano

- Una forma de comparar la evidencia a favor o en contra de $X = x$ a favor de las hipótesis $H_0 : \theta \in \Theta_0$ versus $H_1 : \theta \in \Theta_1$ es comparando las razones

$$\hat{\pi}_j = \frac{E_{\Theta_j}(\ell(\theta))}{E_{\Theta}(\ell(\theta))}, \quad \text{para } j = 0, 1.$$

Podríamos decidir rechazar H_0 en el caso de que $\hat{\pi}_1 > \hat{\pi}_0$.

- En el caso en que $\Theta_0 = \{\theta_0\}$ y $\Theta_1 = \{\theta_1\}$ son hipótesis simples. Para una única observación, tenemos que

$$\hat{\pi}_j = \frac{\pi_j f_{\theta_j}(x)}{\pi_0 f_{\theta_0}(x) + \pi_1 f_{\theta_1}(x)}, \quad \text{para } j = 0, 1,$$

en que $\pi_j = \int_{\Theta_j} \pi(\theta) d\theta = \pi(\theta_j)$ en este caso.

- Finalmente, un test Bayesiano para las hipótesis es dado por

$$T(X) = \begin{cases} 1, & \hat{\pi}_1 > \hat{\pi}_0 \\ 0, & \text{caso contrario.} \end{cases}$$

Definición de Test Minimax

Para las hipótesis:

$$H_0 : \theta \in \Theta_0 \quad \text{vs} \quad H_1 : \theta \in \Theta_1$$

y considerando la **clase admisible**:

$$\mathcal{T}_\alpha = \left\{ T : \sup_{\theta \in \Theta_0} P_\theta(T = 1) \leq \alpha \right\}$$

Definición: un test $T^* \in \mathcal{T}_\alpha$ es *minimax* si:

$$T^* = \arg \min_{T \in \mathcal{T}_\alpha} \sup_{\theta \in \Theta_1} P_\theta(T = 0) \quad \Leftrightarrow \quad \arg \max_{T \in \mathcal{T}_\alpha} \inf_{\theta \in \Theta_1} [1 - P_\theta(T = 0)]$$

Idea: maximiza el poder mínimo bajo H_1 , garantizando el nivel α en H_0 .

Ejemplo: Test Minimax en Estadística Funcional

Modelo funcional no paramétrico:

$$Y(t) = f(t) + \frac{1}{\sqrt{n}} W(t), \quad t \in [0, 1]$$

donde $W(t)$ es ruido blanco y $f \in L^2([0, 1])$ es desconocida.

Hipótesis:

$$H_0 : f = 0 \quad \text{vs} \quad H_1 : f \in \mathcal{F}_\rho = \{f \in \mathcal{H}^s : \|f\|_{L^2} \geq \rho\}$$

Estadístico cuadrático:

$$T_n = \sum_{j=1}^N \left(\int_0^1 Y(t) \phi_j(t) dt \right)^2$$

Resultado minimax:

- Nivel α : $\mathbb{P}_0(T_n > c_n(\alpha)) \leq \alpha$
- Poder uniforme sobre $\mathcal{F}_\rho$ para $\rho \gg n^{-s/(2s+1)}$
- **Test es minimax óptimo** en tasa sobre $\mathcal{H}^s$

¿Por qué usar el enfoque minimax en pruebas de hipótesis?

Situación: El test UMP no siempre existe para H_1 compuesta.

Motivaciones para el abordaje minimax:

- **Generalidad:** Cubre casos donde no hay UMP (e.g., razón de verosimilitud no monótona).
- **Robustez:** Maximiza el poder mínimo sobre $\theta \in \Theta_1$; útil cuando no se conoce θ_1 puntual.
- **Conservador:** Minimiza el riesgo máximo (error tipo II) bajo H_1 ; ideal en contextos críticos.
- **Frecuentista puro:** No requiere distribuciones a priori (vs. enfoque bayesiano).
- **Coherente con teoría de decisiones:** Minimiza pérdida máxima (tipo juego cero-suma).

Aplicación: Pruebas robustas cuando Θ_1 es extensa o incierta.

**Test de la razón de verosimilitud Monótono.
Test Uniformemente Más Poderosos (UMP)
Bilaterales**

Razón de Verosimilitud Monótona (RVM)

Definición 37. Razón de Verosimilitud Monótona (RVM)

Supongamos que el modelo para X está en la clase $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$ dominada por una medida σ -finita. Decimos que $\mathcal{P}$ posee una **Razón de Verosimilitud Monótona (RVM)** en el estadístico $\Psi(X)$ si, y solamente si para $\theta_0 < \theta_1$ cualesquiera, $\lambda(X) = f_1(X)/f_0(X)$ es una función no decreciente de $\Psi(X)$ para valores de X para los cuales al menos $f_1(X)$ y $f_0(X)$ son positivos.

Definición 38. P-valor

El **P-valor** de un test $T(X)$ para las hipótesis $H_0 : P_\theta \in \mathcal{P}_0$ contra $H_1 : P_\theta \in \mathcal{P}_1$ es

$$\text{P-valor} = \sup_{\theta \in \Theta_0} P_\theta(\lambda(X) > \lambda(x_0)),$$

donde $\lambda(\bullet)$ es la RV del modelo. **Regla de decisión:** Rechazamos H_0 , $T(X) = 1$ ssi $\text{P-valor} < \alpha$.

Proposición 5

Si la variable X posee una familia paramétrica $\mathcal{P}$ con RVM $\lambda(\Psi(X))$. Si d es una función no decreciente de $\Psi(X)$, entonces $g(\theta) = Ed(\Psi(X))$ es no decreciente en θ .

Teorema 17. Teorema de Karlin-Rubin

Supongamos que X posee un modelo perteneciente a una familia paramétrica $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$ en que $\Theta \subset R^k$ con RVM $\lambda(\Psi(X))$ en $\Psi(X)$. Consideremos las hipótesis $H_0 : \theta \leq \theta_0$ versus $H_1 : \theta > \theta_0$ en que $\theta_0 \in R$. Entonces:

- (i) Existe un TUP de nivel α que toma la forma de test de la RV: en que c y γ son determinados tal que $\sup_{\theta \in \Theta_0} P_\theta(T(X) = 1) \leq \alpha$.
- (ii) $P_\theta(T(X) = 1) = g(\theta)$ es estrictamente creciente para todo θ para los cuales $0 < g(\theta) < 1$.

Lista de modelos con RVM

Las siguientes familias tienen una Razón de Verosimilitud Monótona (RVM):

- La familia de distribución exponenciales dobles $\{DE(\theta, c)\}$ con una c conocida;
- La familia de distribución exponencial $\{E(\theta, c)\}$ con una c conocida;
- La familia de distribución logística $\{LG(\theta, c)\}$ con una c conocida;
- La familia de distribución uniforme $\{U(\theta, \theta + 1)\}$;
- La familia de distribución hipergeométrica $\{HG(r, \theta, N - \theta)\}$ con valores conocidos r y N ;
- La familia Cauchy $\{Cauchy(\theta, c)\}$ con c conocido no posee RVM.

RVM en familia exponencial

- Si la variable X pertenece a la familia exponencial con densidad

$$f_{\theta}(x) = \exp\{\eta(\theta)\Psi(X) - \xi(\theta)\}h(X)$$

en que $\eta(\theta)$ es una función no decreciente en θ , entonces, su modelo posee una RVM en $\Psi(X)$.

- Si $X \sim \text{Normal}(\theta, \sigma^2)$ para las hipótesis $H_0 : \theta = \theta_0$ contra $H_1 : \theta = \theta_1$ para $\theta_0 < \theta_1$. Entonces, $\lambda(X)$ posee RVM en $\Psi(X) = \sum_{i=1}^n X_i$.
- Si $X \sim \text{Poisson}(\theta)$ para las hipótesis $H_0 : \theta = \theta_0$ contra $H_1 : \theta = \theta_1$ para $\theta_0 < \theta_1$. Entonces, $\lambda(X)$ posee RVM en $\Psi(X) = \sum_{i=1}^n X_i$.
- Si $X \sim \text{Bernoulli}(p, n)$ para las hipótesis $H_0 : p = p_0$ contra $H_1 : p = p_1$ para $p_0 < p_1$. Entonces, $\lambda(X)$ posee RVM en $Y = \sum_{i=1}^n X_i$.

Región de rechazo: caso continuo y discreto

- Si $X \sim \text{Normal}(\theta, \sigma^2)$ para las hipótesis $H_0 : \theta = 0$ contra $H_1 : \theta = 1$ para $n = 9$. Entonces, para $\alpha = 0,05$, $\lambda(X)$ posee RVM en $\Psi(X) = \sum_{i=1}^n X_i$ y $c_\alpha = 4,92$. De esta manera:

$$T(X) = \begin{cases} 1, & \sum_{i=1}^n X_i > 4,92 \\ 0, & \text{caso contrario.} \end{cases}$$

es un TUP de nivel $\alpha = 0,05$.

- Si $X \sim \text{Bernoulli}(n, \theta)$ para las hipótesis $H_0 : \theta = 0,4$ contra $H_1 : \theta = 0,6$. Entonces, $\lambda(X)$ posee RVM en $Y = \sum_{i=1}^n X_i$. Para $\alpha = 0,05$, consideremos un $\gamma = 0,04$ y $m = 9$, luego

$$T(X) = \begin{cases} 1, & Y > 9 \\ 0,04, & y = 9 \\ 0, & Y < 9. \end{cases}$$

es un TUP de nivel $\alpha = 0,05$.

Paso 1: Del Modelo Teórico al Problema Práctico

El Escenario Real:

- Pensemos en un experimento de neurociencia (EEG) donde medimos la actividad cerebral $Y(t)$ después de un estímulo visual.
- **La pregunta clave:** ¿Hay una respuesta cerebral genuina y sistemática ($f(t) \neq 0$) o lo que medimos es solo ruido aleatorio de fondo ($f(t) = 0$)?

Primeros Pasos con los Datos:

- 1 **Discretización de la Señal:** En la práctica, no tenemos una curva continua. Obtenemos una serie de mediciones en puntos de tiempo fijos:

$$Y(t_1), Y(t_2), \dots, Y(t_m)$$

- 2 **Elección de una Base Funcional:** Para analizar la "forma" de la señal, la descomponemos en componentes más simples. Se elige una base $\{\phi_j(t)\}$ apropiada.
 - Para datos periódicos como el EEG, una **base de Fourier** (senos y cosenos) es una elección estándar y muy efectiva.

Paso 2: Cálculo del Estadístico de Test

Una vez elegida la base, cuantificamos cuánta "energía" de nuestra señal reside en cada componente de la base.

Calcular los Coeficientes Empíricos:

- El integral teórico se aproxima mediante una suma numérica.
- Para cada función de la base ϕ_j , calculamos su coeficiente $\hat{\theta}_j$, que mide su contribución a la señal observada:

$$\hat{\theta}_j = \int_0^1 Y(t)\phi_j(t)dt \approx \frac{1}{m} \sum_{k=1}^m Y(t_k)\phi_j(t_k)$$

Calcular el Estadístico de Test Agregado:

- El estadístico T_n suma la energía de todos los coeficientes calculados. Un valor alto sugiere la presencia de una señal estructurada.

$$T_n = \sum_{j=1}^N \hat{\theta}_j^2$$

Siguiente Paso

Paso 3: La Decisión Estadística y Conclusión

El Reto: Encontrar el Umbral Crítico $c_n(\alpha)$

Para tomar una decisión objetiva, comparamos nuestro T_n con un umbral. Este umbral se puede obtener de dos maneras principales:

1. Vía Teórica

- Basado en los libros de Tsybakov/Ingster.
- La teoría asintótica dice que bajo H_0 , T_n sigue una distribución conocida (p.ej., χ^2).
- El umbral $c_n(\alpha)$ es el cuantil $1 - \alpha$ de esa distribución teórica.

2. Vía Simulación

- Se generan miles de "muestras nulas" por permutación o bootstrap.
- Se calcula un T_n^* para cada una.
- Se construye la distribución de estos T_n^* . El umbral es el percentil 95 de esta distribución empírica.

Decisión Final y Conclusión Práctica:

$$\text{Si } T_n > c_n(\alpha) \implies \text{Rechazamos } H_0$$

Conclusión: Existe evidencia estadística significativa para afirmar que el

Test inesgados, Razón de Verosimilitud Generalizada (RVG), función de evidencia y propiedades asintótica.

Tópicos

- En las siguientes condiciones, no es posible aplicar el Lema de Neyman-Pearson para construir un TUP:
 - Cuando el modelo de X no pertenece a la familia exponencial.
 - Cuando H_0 es simple y H_1 es bilateral.
 - Cuando uno de los parametro se asume desconocido (p.e. (μ_0, σ^2))
- Asi como existen estimadores insesgados, también existen tests insesgados, es decir, acotan superior e inferiormente la probabilidad do erro de tipo I y el poder.
- Para hipótesis del tipo generales, la generalización de la estadística de la razón de verosimilitud resulta ser una excelente alternativa.
- Si continuidad de la función de verosimilitud $L_x(\theta) = f_\theta(x)$ es continua, $\sup_{\theta \in \Theta_1} f_\theta(X) = \sup_{\theta \in \Theta} f_\theta(X)$ siempre que $\dim(\Theta) > \dim(\Theta_0)$.
- Cuando empleamos la distribución asintotica de un estadístico de test, para el calculo de probabilidades, esta probabilidad es **aproximada**.
- P-valores asintóticos proximados basados en la distribución asintótica.

Definición 39. Test inesgado

Sea α un nivel de significancia. Un test T para las hipótesis $H_0 : P_\theta \in \mathcal{P}_0$ contra $H_1 : P_\theta \in \mathcal{P}_1$ es llamado de **inesgado** de nivel α si y solo si (i) T es de nivel α y (ii) su poder es al menos α para todo $\theta \in \Theta_1$.

Un test de nivel α es llamado de **Test Inesgado Uniformemente más Poderoso** (TIUP) si y solo si T es TUP e inesgado.


Proposición

Sea $\mathcal{T}_\alpha$ el conjunto de todos los tests de hipótesis $H_0 : \theta \leq \theta_0$ contra $H_1 : \theta > \theta_0$ en una familia exponencial de uniparamétrica, con nivel de significación α . Supóngase que existe un test $T^* \in \mathcal{T}_\alpha$ que es **TIUP**. Entonces, T^* es **minimax** sobre $\mathcal{T}_\alpha$.

Comentario: Este resultado implica que, en hipótesis unilaterales con familia exponencial, el test inesgado óptimo (TIUP) no solo controla el error tipo I y garantiza inesgadez, sino que minimiza el peor poder.

Test Insesgado

Propiedades de un Test Insesgado de Nivel α



Ejemplo: Test TIUP para Tasas Poisson

Modelo y Distribución Condicional Sean $X_1 \sim \text{Poisson}(\lambda_1)$ y $X_2 \sim \text{Poisson}(\lambda_2)$ independientes. Para testear $H_0 : \lambda_2 \leq \lambda_1$ vs $H_1 : \lambda_2 > \lambda_1$, la teoría nos lleva a la distribución condicional de X_2 dado el total $U = X_1 + X_2 = u$:

$$P(X_2 = y | U = u) \sim \text{Binomial}(u, p) \quad \text{donde } p = \frac{\lambda_2}{\lambda_1 + \lambda_2}$$

Función del Test El test TIUP que rechaza H_0 para valores grandes de X_2 (evidencia a favor de H_1) se define por:

$$T'(X_2, U) = \begin{cases} 1 & \text{si } X_2 > c(U) \\ \gamma(U) & \text{si } X_2 = c(U) \\ 0 & \text{si } X_2 < c(U) \end{cases}$$

Donde los valores críticos $c(u)$ y $\gamma(u)$ se obtienen de los cuantiles de la distribución $\text{Binomial}(u, 1/2)$ para asegurar que el test tenga un nivel de significancia α .

Teorema 18

Para testar las hipótesis $H_0 : \theta \leq \theta_0$ contra $H_1 : \theta > \theta_0$, un TIUP de nivel α es un test

$$T'(Y, U) = \begin{cases} 1, & Y > c(U) \\ \gamma(U), & Y = c(U) \\ 0, & Y < c(U). \end{cases}$$

en que $c(u)$ y $\gamma(u)$ son funciones de Borel determinadas por $E_{\theta_0}(T'(Y, U)|U = u) = \alpha$, para todo u y E_{θ_0} es el valor esperado con respecto a $f_{\theta_0, \psi}$.

Ejemplo:

- Decimos que el modelo de X pertenece a la **familia exponencial natural multiparametrica** si su función de densidad o función de probabilidad:

$$f_{\theta, \psi} = \exp\{\theta Y(x) + \psi^\top U(x) - \zeta(\theta, \psi)\} h(x),$$

en que θ es un vector y $\psi(\theta)$ a valores reales.

Tipo de hipótesis y contraste de hipótesis

- **Hipótesis simple:** $H_i : \theta \in \{\theta_i\}$ o $H_i : \theta = \theta_0$. Determinan un punto del espacio paramétrico.
- **Hipótesis compuesta:** $H_i : \theta \in \Theta_0$ con $\dim(\Theta_i) \geq 1$. Determinan un subconjunto no simple del espacio paramétrico.
- **Contraste unilateral a la derecha** para un parámetro θ : $H_0 : \theta = \theta_0$ contra $H_1 : \theta \geq \theta_0$.
- **Contraste unilateral a la izquierda** para un parámetro θ : $H_0 : \theta = \theta_0$ contra $H_1 : \theta \leq \theta_0$.
- **Contraste bilaterales:** $H_0 : \theta = \theta_0$ contra $H_1 : \theta \neq \theta_0$. (p.e. $H_0 : \mu = \mu_0$ contra $H_1 : \mu \neq \mu_0$).

Consideremos un modelo Normal bivariado y dos hipótesis anidadas:

- $H_{01} : \mu_1 = \mu_2 = 0$ (Hipótesis específica)
- $H_{02} : \mu_1 = \mu_2$ (Hipótesis general, que contiene a H_{01})

Hipótesis sobre Subconjuntos Paramétricos Generales

Idea Central: Una hipótesis general se formula como:

$$H_0 : \theta \in \Theta_0 \quad \text{versus} \quad H_1 : \theta \in \Theta_1$$


donde Θ_0 es un subconjunto de Θ que puede tener una estructura geométrica compleja (no ser solo un punto o un intervalo).

Ejemplos de Subconjuntos Paramétricos (Θ_0)

- **Hipótesis Lineal:** En una regresión con parámetros (β_1, β_2) , la hipótesis $H_0 : \beta_1 = \beta_2$ define a Θ_0 como una línea en el plano $\mathbb{R}^2$.
- **Hipótesis No Lineal (Curvatura):** La hipótesis $H_0 : \beta_1^2 + \beta_2^2 = 1$ define a Θ_0 como la circunferencia de un círculo unitario.
- $H_0 : \beta_1 = 0, \beta_2 = \beta_3$ (un Plano)
- **Hipótesis Anidadas:** El punto $H_{01} : (\mu_1, \mu_2) = (0, 0)$ es un subconjunto de la línea $H_{02} : \mu_1 = \mu_2$.

Máximo y supremo de una función

Comparación: Máximo vs. Supremo en un Mismo Gráfico



Test de la Razón Verosimilitud (TRV)

Consideremos las hipótesis generales: $H_0 : \theta \in \Theta_0$ contra $H_1 : \theta \in \Theta_1$, en que $\Theta_0 \cup \Theta_1 = \Theta$, $\Theta_1 \cap \Theta_0 = \emptyset$ y Θ_1 y Θ_0 son no vacíos.

Definición 40

Sea $L_x(\theta) = f_\theta(x)$ la función de verosimilitud del modelo para $X = x$. Para testar $H_0 : \theta \in \Theta_0$ contra $H_1 : \theta \in \Theta_1$, la Razón de Verosimilitud (TRV) y la región de rechazo es:

$$\lambda(X) = \frac{\sup_{\theta \in \Theta_1} f_\theta(X)}{\sup_{\theta \in \Theta_0} f_\theta(X)} \quad \text{y} \quad A_1 = \{x \in \Lambda : \lambda(x) \geq c\},$$

que rechaza H_0 si, y solo si $\lambda(X) < c$. El razonamiento para el test es el siguiente: si H_0 es verdadera, $\lambda(X)$ tendrá valores cerca de 0, en cambio si H_1 es verdadera, $\lambda(X)$ tiende tener valores cercanos a 1.

Test de la Razón Verosimilitud Generalizada (TRVG)

Sean $\hat{\theta}_0$ y $\hat{\theta}_1$ los estimadores de máxima verosimilitud de θ sobre Θ_0 y Θ_1 . Entonces, la estadística TRV:

$$\lambda(X) = \frac{f_{\hat{\theta}_1}(X)}{f_{\hat{\theta}_0}(X)}.$$

Para un cierto $\alpha \in (0, 1)$, si existe una constante c_α tal que

$$P_\theta(\lambda(X) < c_\alpha) = \alpha \forall \theta \in \Theta_0, \text{ el test } \lambda(x) \text{ tiene nivel } \alpha.$$

Definición 41

El estadístico $\lambda'(x)$ y la región de rechazo A_1

$$\lambda'(X) = \frac{\sup_{\theta \in \Theta_0} f_\theta(X)}{\sup_{\theta \in \Theta} f_\theta(X)} \text{ y } A_1 = \{x \in \Lambda : \lambda'(x) \leq c\}.$$

forman el **Test de la Razón de Verosimilitud Generalizada (TRVG)**.

Si H_0 es verdadera, $\lambda'(X)$ tendrá valores cerca de 0, si H_1 es verdadera, $\lambda'(X)$ tendrá valores cercanos a 1.

Teorema 19. Convergencia en distribución de $-2 \log(\lambda'_n(X))$

Sean las hipótesis $H_0 : \theta \in \Theta_0$ contra $H_1 : \theta \in \Theta_1$, en que $d_1 = \dim(\Theta)$ y $d_2 = \dim(\Theta_0)$. Sobre H_0 y las condiciones del Teorema 6,

$$-2 \log(\lambda'_n(X)) \rightarrow_d \chi_k^2,$$

en que $k = d_1 - d_2$.

Ejemplo de hipótesis y dimensiones:

- Si $B \subset R^k$, entonces $\dim(B) = k$. También, para $\theta_0 \in B$, tenemos que $\dim(\{\theta_0\}) = 0$, dado que θ_0 no tiene longitud, altura ni anchura, etc.
- Sea $\theta \in \Theta_0$, si los componentes $\theta_{10}, \dots, \theta_{s0}$ de θ son conocidos y fijos sobre $H_0 : \Theta_0$, para $s < k$, entonces $\dim(\Theta_0) = k - s$.

Aplicaciones del TRVG a test bilaterales

- Modelo Normal. Test para una media con varianza desconocida
 $H_0 : \mu = \mu_0$. Rechazo:

$$\frac{\sqrt{n}(\bar{X} - \mu_0)}{S} \leq -c_\alpha \quad \text{or} \quad \frac{\sqrt{n}(\bar{X} - \mu_0)}{S} \geq c_\alpha$$

- Modelo Normal. Test para una varianza con media desconocida
 $H_0 : \sigma^2 = \sigma_0^2$. Rechazo:

$$\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma_0^2} \leq c_1 \quad \text{or} \quad \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma_0^2} \geq c_2.$$

- Modelo Poisson. Test para una media $H_0 : \theta = \theta_0$. Rechazo:

$$-2 \log \lambda'(X) \geq \chi_\alpha^2, \text{ cuantil asintótico.}$$

Medida de evidencia para H_0

Propiedades de una medida de evidencia

Sea $s : \mathcal{X} \times \mathbb{P}(\Theta) \rightarrow [0, 1]$ una función que, para una hipótesis nula $H_0 : \theta \in \Theta_0$, cumple las siguientes propiedades:

- 1 $s(\emptyset) = 0$ y $s(\Theta) = 1$.
- 2 Si $\Theta_{01} \subseteq \Theta_{02}$, entonces $s(\Theta_{01}) \leq s(\Theta_{02})$.

Una medida de evidencia para H_0 es una métrica normalizada para la fuerza de la evidencia a favor de H_0

- $j\lambda'(X)$ es una medida de evidencia?
- Si, RVG cumple con las propiedades, pero el p-valor basada en ella no.

El s-value: Una Medida de Evidencia Coherente

Definición del s-value (Forma Simplificada)

Bajo condiciones de regularidad, el s-value para una hipótesis nula $H_0 : \theta \in \Theta_0$ se calcula como:

$$s(\Theta_0) = 1 - F(T_{\Theta_0})$$

donde $T_{\Theta_0} = 2(l(\hat{\theta}) - l(\hat{\theta}_0))$ es el estadístico de la razón de verosimilitud y F es la cdf de su distribución.

Propiedades Fundamentales

El s-value cumple las propiedades matemáticas de una medida de evidencia:

- **Límites definidos:** $s(\emptyset) = 0$ y $s(\Theta) = 1$.
- **Consistencia para hipótesis anidadas:** Si $\Theta_{01} \subseteq \Theta_{02}$, entonces $s(\Theta_{01}) \leq s(\Theta_{02})$.

Coherencia: s-value vs. p-value (Ejemplo Unificado)

Consideremos un modelo Normal bivariado y dos hipótesis anidadas:

- $H_{01} : \mu_1 = \mu_2 = 0$ (Hipótesis específica)
- $H_{02} : \mu_1 = \mu_2$ (Hipótesis general, que contiene a H_{01})

Resultados para la misma data observada

Medida	Para H_{01}	Para H_{02}
p-value	0.10	0.03
s-value	0.104	0.105

Análisis

- **p-value** → **Incoherente**: Se encuentra más evidencia contra la hipótesis general ($p_2 < p_1$), lo cual es ilógico. Esto ocurre porque cada p-value usa una distribución de referencia distinta.
- **s-value** → **Coherente**: La evidencia para la hipótesis específica es menor ($s_1 < s_2$), respetando la lógica de anidamiento.

Referencias

- Patriota, AG. A classical measure of evidence for general null hypotheses . Fuzzy sets and Systems, 233, 74-88, (2013).
- Patriota, AG. A measure of evidence based on the likelihood-ratio statistics Statistical Papers, 63, 1931-1951, (2022).
- Royall, R. (2017). Statistical evidence: a likelihood paradigm. Routledge.

Tests del tipo Chi-cuadrado.

Ensayos Bernoulli. Modelo Binomial y Multinomial

- Ensayos Bernoulli: procedimiento con evento binario.
- Secuencia de Ensayos Bernoulli: procedimiento en el cual se observa un evento binario un número finito de veces (p.e. lanzar 10 monedas al aire observar las caras). Los eventos son independientes y en cada ensayo el “éxito” tiene la misma probabilidad.
- Considerar una secuencia de variables Bernoulli $Y_1, \dots, Y_n$ en que en cada ensayo $\Omega = \{a_1, a_2\}$. Luego

$$Y_i(a) = \begin{cases} 1, & \text{si } a = a_1, \\ 0, & \text{caso contrario.} \end{cases}$$

- Una variable Binomial cuenta la cantidad de éxitos en n ensayos Bernoulli, es decir,

$$B(\omega) = \sum_{j=1}^n Y(\omega_j),$$

en que $\omega = (\omega_1, \dots, \omega_n)$ y $\omega_j = a$.

Ejemplos de datos Multinomial

- Consideremos un experimento que consiste en escoger con reposición de forma aleatoria uno de los k elementos en

$$\Omega = \{\omega_1, \dots, \omega_k\}.$$

- Consideremos una repetición de este experimento n veces. ¿Cuántas veces se observó ω_j en las n repeticiones?, para $j = 1, \dots, k$.
- En el i -ésimo experimento para $i = 1, \dots, n$ y sea $Y_i(\omega_j)$ la i -ésima variable Bernoulli y

$$X_j = \sum_{i=1}^n Y_i(\omega_j),$$

es el número de veces en que ω_j fue elegido.

- Finalmente, el $X = (X_1, \dots, X_k)$ es el vector de número de veces en que observado cada elemento del vector $\omega = (\omega_1, \dots, \omega_k)$.

F. de probabilidad Bernoulli, Binomial y Multinomial

■ Bernoulli

$$f_{\theta}(x) = \theta^x(1 - \theta)^{1-x}.$$

■ Binomial

$$f_{\theta}(x) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}$$

■ Multinomial

$$f_{\theta}(x_0, x_1, \dots, x_k) = \frac{n!}{x_0! x_1! \dots x_k!} p_0^{x_0} p_1^{x_1} \dots p_k^{x_k}$$

Test del tipo Chi-cuadrado

Definición 40. Test y estadístico Chi-cuadrado

Sea $X = (X_1, \dots, X_k) \sim \text{Multinomial}(\mathbf{p})$, en que $\mathbf{p} = (p_1, \dots, p_k)$, $\sum_{j=1}^k p_j = 1$.

Para las hipótesis

$$H_0 : \mathbf{p} = \mathbf{p}_0 \quad \text{versus} \quad H_0 : \mathbf{p} \neq \mathbf{p}_0,$$

en que $\mathbf{p}_0 = (p_{01}, \dots, p_{0k})$. Tenemos los siguientes estadísticos para una función test:

$$T_0 = \sum_{j=1}^k \frac{(X_j - np_{0j})^2}{np_{0j}} \quad \text{y} \quad T_{00} = \sum_{j=1}^k \frac{(X_j - np_{0j})^2}{X_j}.$$

- Los estadísticos T_0 y T_{00} son llamados estadísticos del tipo Chi.cuadrado (χ^2).

Convergencia en distribución de T_0 y T_{00}

Teorema 20

Sea T_0 y T_{00} los estadísticos del tipo Chi-cuadrado, entonces

$$T_0, T_{00} \rightarrow_d \chi_{k-1}^2 \quad \text{cuando } n \rightarrow \infty.$$

- Un test asintótico T rechaza H_0 es dado por

$$T(X) = \begin{cases} 1, & \text{si } T_0 \text{ (o } T_{00}) > \chi_{k-1, \alpha}^2, \\ 0, & \text{caso contrario.} \end{cases}$$

en que $\chi_{k-1, \alpha}^2$ es el cuantil asintótico de T_0 o T_{00} .

Test no paramétricos.

Supuestos no paramétricos

- Un modelo no paramétrico se construye sobre supuestos de ideas intuitivas de una clase $\mathcal{P}$.
- En general, las suposiciones sobre $\mathcal{P}$ son bastante generales y minimalistas.
- Si los datos fueron generados por un modelo no paramétrico, entonces no siempre existen test del tipo TUP o TIUP.
- Si existen test de nivel α exacto o asintótico.
- Los estadísticos del test, en general, no tendrán función de probabilidad acumulada exacta. Entonces, emplearemos su modelo asintótico.

Modelo no paramétrico

Definición 41. Modelo estadístico no Paramétrico

Un **modelo estadístico no paramétrico** es una tripla

$$\left(\Lambda, \mathcal{G}, \{P_s : s \in S\}\right),$$

en que s es una **función** que pertenece a una clase de funciones S bien definida. Por ejemplo, el espacio L^2 en los reales o en el intervalo unitario. La función s puede ser, por ejemplo, la función de densidad $f(x)$ o función de probabilidad acumulada $F(x)$ descrita en términos de propiedades funcionales.

- $S = \left\{ F : \int_{-\infty}^{\infty} x dF(x) < \infty \right\}.$
- $S = \left\{ F : \int |x|^2 dF(x) < \infty \right\}.$
- $S = \left\{ F : \int |xy|^2 dF(x, y) < \infty \right\}.$
- $S = \{f : f \text{ es simétrica}\} \text{ o } S = \{F : F \text{ es continua}\}.$

Test de signos

Sea $X_1, X_2, \dots, X_n$ una secuencia i.i.d con función de probabilidad acumulada F continua. Sea $x_0 \in \Lambda$ tal que $p = F(x_0)$ (x_0 es un cuantil de orden $1 - p$). Definimos **el signo** de X_i con respecto a x_0 :

$$\Delta(X_i) = \begin{cases} 1, & X_i - x_0 \leq 0, \\ 0, & X_i - x_0 > 0. \end{cases}$$

- Test de signos de una muestra. Sea $p = P(\Delta(X_i) = 1)$ para todo i e $Y = \sum_{i=1}^n \Delta(X_i)$.
 - $H_0: p \leq p_0$ contra $H_0: p \geq p_0$
 - $H_0: p = p_0$ contra $H_0: p \neq p_0$.

$$T(X) = \begin{cases} 1, & Y > m, \\ \gamma, & Y = m, \\ 0, & Y < m. \end{cases} \quad T'(X) = \begin{cases} 1, & Y < c_1 \text{ o } Y > c_2, \\ \gamma_i, & Y = c_i, i = 1, 2. \\ 0, & c_1 < Y < c_2. \end{cases}$$

Test de signos para dos muestras

Sea $X_1, \dots, X_n, Y_1, \dots, Y_n$ y las diferencias $Z_i = X_i - Y_i$ para $i = 1, 2, \dots, n$ con f.p.a F' . Sea z_0 tal que $p = F'(z_0)$.

- Test de signos de dos muestras.
 - $H_0 : p = p_0$ contra $H_0 : p \neq p_0$.
- Test de la mediana (s).
 - Para el caso de una muestra $X_1, \dots, X_n$ y sea η tal que $0,5 = F(\eta)$. Luego $H_0 : p = 0,5$ es equivalente a $H_0 : \eta = \eta_0$ (análogo a $H_0 : \mu = \mu_0$).
 - Para el caso de $Z_i = X_i - Y_i$ para $i = 1, 2, \dots, n$ con f.p.a F' para dos muestras de X e Y . Sea η tal que $0,5 = F'(\eta)$. Luego $H_0 : p = 0,5$ es equivalente a $H_0 : \eta_1 = \eta_2$ (análogo a $H_0 : \mu_1 = \mu_2$).

Estadísticos de orden y posiciones

Definición 42.

Sea $X_1, \dots, X_n$ una muestra aleatoria i.i.d. Los **estadísticos de orden** $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ tal que $X_{(1)} < X_{(2)} < X_{(n)}$. El **rank** o **posición** r_i de X_i es denotado por $R(X_i) = r_i$ es tal que $X_i = X_{(r_i)}$. La posición r_i es la posición de X_i en la secuencia de estadísticos de orden. Denotamos por $R(X)$ el **vector de rangos** de $X_1, \dots, X_n$.

Sea $\bar{R}(X)$ el vector de las posiciones de $|X_1|, \dots, |X_n|$. Sea $R_+(X)$ el subvector de $R(X)$ que contiene todos las posiciones de los valores positivos de X_i . Sea $R_+(X)^\circ$ los rangos ordenados de $R_+(X)$.

Un test basado en $R_+(X)^\circ$ es llamado de **test de posiciones de signos** para una muestra para las hipótesis: $H_0 : F$ es simétrica alrededor de 0 contra $H_1 : F$ no es simétrica alrededor de 0.

Test de posiciones

■ Test de posiciones de una muestra.

- El estadístico de rangos es definido por

$$W(R_+(X)) = R_{+1}^o/n + R_{+2}^o/n + \dots + R_{+n_0}^o/n,$$

en que R_{+i}^o es el i -ésimo componente de R_+^o . Estadístico $W(R_+(X)^o)$.

- La función test es dada por

$$T(X) = \begin{cases} 1, & W(R_+^o) < c_1 \text{ o } W(R_+^o) > c_2, \\ \gamma, & W(R_+^o) = c_i, i = 1, 2, \\ 0, & c_1 < W(R_+^o) < c_2. \end{cases}$$

■ Test de posiciones de dos muestras.

- Sea $X_1, \dots, X_n, Y_1, \dots, Y_n$ y las diferencias $Z_i = X_i - Y_i$ para $i = 1, 2, \dots, n$ con f.p.a F' . Consideremos las hipótesis $H_0 : F_1 \equiv F_2$ contra $H_1 : F_1(a) \leq F_2(a)$ para todo a .

■

$$T(X) = \begin{cases} 1, & R_x = \sum_i^n R(X_i) < c_\alpha \\ 0, & \text{Caso contrario.} \end{cases}$$

Test de Kolmogorov

■ Test de Kolmogorov de una muestra.

- Sea $X_1, X_2, \dots, X_n$ una secuencia i.i.d con función de probabilidad acumulada F continua.
- $H_0 : F \equiv F_0$ contra $H_1 : F \neq F_0$ ($\exists x : F(x) \neq F_0(x)$).
- Se considera el estadístico D_n por

$$D_n = \sup_{x \in \Lambda} \{|F_n(x) - F_0(x)|\}, \quad F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{(-\infty, x]}(x_i).$$

- Función test de Kolmogorov:

$$T(X) = \begin{cases} 1, & D_n > c_\alpha \\ 0, & \text{caso contrario.} \end{cases}$$

■ Test de Kolmogorov de dos muestras.

- Sea $X_1, \dots, X_{n_1}, Y_1, \dots, Y_{n_2}$ con d.p.a F_1 y F_2 , respectivamente.
- $H_0 : F_1 = F_2$ contra $H_1 : F_1 \neq F_2$.
- Definimos el estadístico

$$D_{n_1 n_2} = \sup_{x \in \Lambda} \{|F_{n_1}(x) - F_{n_2}(x)|\} \quad T(X) = \begin{cases} 1, & D_{n_1 n_2} > c_\alpha \\ 0, & \text{caso contrario.} \end{cases}$$

Test de ANOVA no paramétrico

Consideremos una secuencia de k muestras aleatorias con f.p.a $F_1, \dots, F_k$, y medianas $\eta_1, \dots, \eta_k$, respectivamente.

- Test de Kruskal-Wallis.

- $H_0 : \eta_1 = \dots = \eta_k$
- $H_1 : \exists : j_1, j_2 : \eta_{j_1} \neq \eta_{j_2}$.
- Si rechazamos H_0 , se concluye que los grupos son diferentes en términos de las medianas.

Referencias

- Pereira C. (1993). Teoría Estadística. Monografias do IMPA, Rio de Janeiro. Disponible online: .
- Rincón, L. (2019). Una introducción a la estadística inferencial. México: Las prensas de Ciencia.
- Sen, P. K., & Singer, J. M. (2017). Large sample methods in statistics (1994): An introduction with applications. CRC press.
- Shao, J. (2003). Mathematical Statistics. Springer Science & Business Media.
- Bolfarine, H., & Sandoval, M. C. (2001). Introdução à inferência estatística (Vol. 2). SBM.